

Cours 1 Extraction Connaissances Et Applications Bases de Données

NB : Pour les TD Machines, bien faire en sorte d'être toujours sur le même poste ;


Jeudi 4/09 et Vendredi 5/09, CC sur ce qui aura été vu lundi mardi mercredi.

1 partie du cours avec Agastya, 1 autre avec Maabout, les 2 parties sont indépendantes entre elles.

Extraction de données : récupération d'informations pour les rendre utiles et exploitables

16h de cours : récupération de données, métiers couverts par cela, methodo autour des normes CAP...

Construire un diagramme de classe sur un domaine d'activité choisi : **SPOTIFY**



Jointure : Requête SQL la plus coûteuse. (i.e. la plus gourmande, la plus longue à exécuter)

➔ **Objectif** : Minimiser le nombre de jointures

Quelques problématiques en entreprise :

Un admin va utiliser un panel pour accéder à une BDD.

La BDD est initialement en 100% locale. Mais il est décidé de transiter vers une bdd sous Cloud. Mais actuellement il est impossible de transvaser l'intégralité de la BDD sur le Cloud, donc il y'aura une grande partie sur le Cloud, et une autre qui sera toujours sur la BDD Locale. Le cloud est dit « scalable », cela signifie que son stockage peut s'agrandir (ou se réduire) en cas de besoin à un instant t.

Pour ce qui reste en local, il va être séparé en deux grandes parties : Archives et Opérationnel. Opérationnels va contenir les éléments « récents » tandis que ceux dans les archives vont être ceux qui sont plus anciens et qui auront moins de chances d'avoir à être traités.

Deux grands aspects qui posent problèmes en entreprise :

- Vision court-termiste
- Problème au niveau du reporting puisque chaque bdd est indépendante par rapport aux autres, et elles sont gérées possiblement par différentes personnes, ce qui signifie que les infos qui concernent plusieurs bdd risquent d'être difficiles à retrouver.

Objectif : Fournir des outils aux utilisateurs qui n'ont vraiment de connaissances en SQL afin de leur permettre de naviguer librement dans la bdd.

Les entreprises doivent répondre à des problématiques juridiques, des réglementations légales comme la **RGPD**, le **CNIL**...

On prend toutes les BDD en **Opérationnels** (bdd sous Cloud, ou bien un fichier plat, ou une bdd locale) et on va essayer d'avoir un **processus** qui va être monitoré et automatisé qui va permettre d'avoir un report qui sera consommable par l'utilisateur final.

On va parler d'une structure qui va permettre de stocker les données : le **DATAWAREHOUSE**

DataWarehouse (DWH) :

Datawarehouse (ou entrepôt de données) base de données utilisées pour faciliter la prise de décision.

4 règles du DWH :

- **Orienté sujet**
 - *Le DWH va être focalisé sur UN domaine fonctionnel précis.*
 - *La DWH va piocher dans les bdd à disposition uniquement les infos sur la thématique qui nous intéresse.*
- **Intégré**
 - *Les données viennent de plusieurs sources, mais il faut que ces données soient harmonisées dans un format commun afin de mieux les analyser.*
- **Non Volatile**
 - *Toute données rentrées dans le datawarehouse n'en ressort plus (on ne supprime pas de l'information)*
- **Historisé**
 - *A chaque fois que l'on met à jour notre DWH, il faut savoir de quand nos données ont été archivées. Utile pour suivre les évolutions.*

En entreprise, il existe souvent des « faux DWH », car ils sont volatiles et non historisés

OLTP : Online Transactionnal Process

OLAP : Online Analytical Process

Quelles sont les différences entre OLTP et OLAP :

- **OLTP** est plus axé « **opérationnel** », il va être utilisé sur le traitement de données sur un instant T. Il va enregistrer et gérer les transactions en temps réel. Ce process se doit être rapide étant donné que sa qualité/rapidité va impacter la qualité des transactions. Il va gérer un volume agrégé de transactions. On va privilégier les transactions. Modélisation en forme normale. L'OLTP va être utilisé par les employés/techniciens.
- Enregistrer et traiter les passages en caisse d'un client = **OLTP**.
- **OLAP**, lui, est plutôt axé « **décisionnel** », il va s'occuper de l'analyse des nombreuses données historisées afin de faciliter la prise de décision. Il va traiter un nombre de données beaucoup plus grands et plus lourds. Le traitement va donc mettre plus de temps. En OLAP, on va privilégier généralement les LECTURES. Modélisation en forme Etoile/flocon. Va être utilisé par les analystes.
- Prévoir le nombre de caissiers pour le 24 décembre à partir des historiques des années précédentes = **OLAP**.

OLAP	OLTP
BDD utilisé pour la prise de décision	BDD utilisé pour le traitement d'information opérationnel
donnée issue d'anciennes sources (+ intégré)	donnée issue de BDD transactionnel en temps réel
Plus lourd en terme de volumétrie (To) mais moins de requête (lecture uniquement)	plus léger car mis à jours (Go) mais beaucoup de requête
traitement plus long et coûteux	traitement plus rapide et plus logique
OLAP permet d'analyser les tendances, de prévoir le comportement des clients et d'identifier la rentabilité	OLTP convient au traitement des paiements, à la gestion des données clients et au traitement des commandes
Architecture centré sur la lecture	Architecture centré sur la transaction
modélisation étoile / flocon	modélisation forme Normale (3)
utilisé par les décideurs , les analystes	utilisé par les techniciens / employés

Le « O » pour Online désigne en partie la même chose que pour les « AAS » (As a Service)

Le parallèle avec les « AAS » (As a Service)

Quand on parle de IaaS, PaaS, SaaS, le terme « As a Service » est directement lié à la notion **Online** car :

- Tout est **fourni via Internet (le Cloud)**, sans qu'on ait besoin de gérer soi-même l'infrastructure.
- Tu **consommes** une ressource **à la demande** et en **temps réel**, comme un service accessible en ligne.

Donc :

- **Online** → accès immédiat, interactif, temps réel.
- **As a Service** → accès immédiat, mutualisé, à la demande, via le réseau.

Le « O » de **Online** dans OLTP/OLAP a une philosophie proche de celle des **AAS** → rendre les systèmes **disponibles en temps réel, via le réseau, de manière souple et accessible**.

La différence est que dans OLTP/OLAP, Online est surtout appliqué au **traitement des données**, alors que dans AAS, Online est appliqué au **mode de fourniture du service informatique**.