



Cours 2 ECABD

On va évoquer différents outils du DWH :

- **L'ETL (Extract Transform Load)**
 - Permet de déplacer des données d'un endroit A vers un endroit B.
 - L'ETL se connecte aux différentes bases de données sources, récupère les données, les transforme si nécessaire, puis les charge dans un nouvel espace de stockage appelé ODS (Operational Data Store).
 - L'ODS centralise les informations pour les rendre disponibles sans impacter les systèmes opérationnels (OLTP), ce qui permet d'éviter toute incohérence dans les données.
 - Au début on va juste Extraire et Charger un ODS nos données, mais la transformation va se faire lorsque l'on va extraire nos données de l'ODS vers le DWH (on transforme de manière à ce que nos données respectent nos 4 règles énoncées précédemment)
 - Un **Data Mart** est une **sous-partie d'un Data Warehouse (DWH)**, conçue pour répondre à des besoins spécifiques d'une **équipe, d'un service ou d'un domaine particulier**. Les Datamarts ne communiquent pas entre eux. Des données d'un DWH peuvent être communs à plusieurs Datamarts.



- **DWH (Data Warehouse)** : c'est une **grosse base de données centralisée**, qui **regroupe toutes les données de l'entreprise** provenant de différents domaines fonctionnels (finance, marketing, production, ventes, etc.) pour **l'analyse globale et la prise de décision**.
- **Data Mart** : c'est un **sous-ensemble du DWH**, conçu pour **un seul domaine fonctionnel ou une équipe spécifique**. Il contient seulement les données pertinentes pour ce domaine, souvent **agrégées ou filtrées** pour faciliter les analyses et le reporting.



ETL utilisé en cours : **TALAN**

Dans le rapport, on va des indicateurs pour monitorer suivre, prendre une décision... dans le diagramme de classe on veut identifier les éléments qui pourraient être des indicateurs (cf diagramme de classe cours 1)

Liste d'indicateurs :

- *Indicateur sur les genres les plus mis en avant*
- *Indicateur sur les musiques les plus likées*
- *Indicateur sur les musiques les plus rajoutées dans les playlists*
- *Indicateur sur les musiques écoutées jusqu'à la fin*
- *Indicateur sur le nombre de nouveaux utilisateurs à la journée...*
- *Indicateur sur le nombre de musiques mis en ligne*

Avantages et Inconvénients :

- **Avantages :**
 - *Facilité de trier les musiques par genre*
 - *Traçabilité d'une musique simple*
 - *Pas de redondance de données*
- **Inconvénients :**
 - *Pas de nombre de vues pour trier les musiques par popularité*
 - *Besoin d'énormément de jointures pour avoir accès à toutes les infos concernant une musique en particulier (artiste, album, playlist...)*
 - *Pas d'historisation des écoutes*


On va créer deux types de tables :

- Tables de dimensions
 -
- **Tables de faits**
 - C'est ce qu'on veut quantifier
 - Représente un sujet d'analyse que l'on veut mesurer
 - Généralement en format Numérique
 - Contient les éléments techniques qui vont permettre des liaisons avec les tables de dimensions
 - NB : Il y'a dedans autant de clés étrangères dans cette table que de nombre de tables de dimensions.
 - Ex : Montants de ventes, quantités vendues etc...
 - Peut être :
 - **Additif** : Peut s'additionner en ayant du sens (**ex** : prix)
 - **Semi-additif** : On peut l'additionner mais ça n'a pas de sens (**ex** : addition de températures)
 - **Non-additif** : Ne peut pas s'additionner (**Ex** : des couleurs)
 - Le nombre de lignes d'une table de faits :
 - **Somme de Produit de $i=1$ à n du nombre de ligne de la dimension i**
 - S'il y'a n dimensions, il y'a n jointures -> Modélisation Etoile

Granularité : Mesure afin de déterminer si notre table de dimension est détaillée ou non

Ex : Table de dimension LIEU

- ➔ S'il y a juste le nom de la ville, ce sera une granularité faible, mais si on rajoute des lignes dans la table comme le département ou le pays, ça augmente la granularité.
- ➔ Plus la table est remplie, plus la granularité est forte.
- ➔ Le fait d'avoir des tables « granulaires » va créer des redondances (au niveau des départements qui vont être répétés), mais on va privilégier un nombre moins important de jointures (i.e. éviter de créer d'autres tables de dimensions DEPT ou PAYS)




Modélisation en étoile (autant de jointures que de dimensions)

Ces tables vont être modélisées :


- En étoile (une seule table des faits)
- Flocons (une seule table des faits)
- Constellation (plusieurs tables des faits)

Comment passer de modélisation en étoile à flocon ?



Modélisation en flocon

On a besoin d'historiser nos données, donc on va relier à notre table de FAITS une nouvelle table de dimensions TEMPS.



Modélisation en flocon historisée


Modélisation en constellation : Deux (ou plus) modélisations en étoile (ou flocon), avec en lien une table de dimension en commun.

c) Modèle Constellation (ou Galaxy Schema) 🌌

- Plusieurs tables de faits partagent des tables de dimensions communes.
- Exemple :
 - Table de faits Ventes
 - Table de faits Livraisons
 - Toutes deux partagent la dimension Produit et Date.
- Avantage : adapté quand on a plusieurs processus métiers (ventes, achats, stocks).
- Inconvénient : schéma plus complexe à gérer.

48

Modèle en Constellation - Exemple



Avantage de ces modèles :

→ **Organisation** : les services sont silottés (chaque service, sont isolés) -> Pas de communication entre elles.

SCD : Slowly Changing Dimension

Un SCD (Slowly Changing Dimension) correspond à une dimension dont les données évoluent lentement dans le temps (ex. : adresse d'un client, service d'un employé, catégorie d'un produit).
Le défi est de savoir comment gérer l'historique de ces changements dans un entrepôt de données.

3 options :

- 1. Remplacement : On écrase l'ancienne valeur par la nouvelle
- 2. Historisation : On update notre valeur, on rajoute un nouveau bloc et on y insère notre nouvel élément
- Compliqué si beaucoup de valeurs à changer
- 3. Je conserve mon identifiant et le nom de mon produit, mais au lieu de rajouter une ligne, je rajoute une colonne


Remplacement	Un SCD (Slowly Changing Dimension) correspond à une dimension dont les données évoluent lentement dans le temps (ex. : adresse d'un client, service d'un employé, catégorie d'un produit). Le défi est de savoir comment gérer l'historique de ces changements dans un entrepôt de données.																		
Historisation	Exemple : Même cas avec Jean Dupont. <table><tr><th>Client_ID</th><th>Nom</th><th>Ville</th><th>Date_Debut</th><th>Date_Fin</th><th>Actif</th></tr><tr><td>101</td><td>Jean Dupont</td><td>Paris</td><td>01/01/2023</td><td>31/12/2023</td><td>0</td></tr><tr><td>102</td><td>Jean Dupont</td><td>Lyon</td><td>01/01/2024</td><td>NULL</td><td>1</td></tr></table> ➡ On sait qu'il habitait Paris avant, puis Lyon maintenant.	Client_ID	Nom	Ville	Date_Debut	Date_Fin	Actif	101	Jean Dupont	Paris	01/01/2023	31/12/2023	0	102	Jean Dupont	Lyon	01/01/2024	NULL	1
Client_ID	Nom	Ville	Date_Debut	Date_Fin	Actif														
101	Jean Dupont	Paris	01/01/2023	31/12/2023	0														
102	Jean Dupont	Lyon	01/01/2024	NULL	1														
Historisation en temps limité	Exemple : Toujours Jean Dupont. <table><tr><th>Client_ID</th><th>Nom</th><th>Ville_Actuelle</th><th>Ville_Precedente</th></tr><tr><td>101</td><td>Jean Dupont</td><td>Lyon</td><td>Paris</td></tr></table> ➡ On sait juste qu'il habitait Paris avant, mais pas ses adresses encore plus anciennes.	Client_ID	Nom	Ville_Actuelle	Ville_Precedente	101	Jean Dupont	Lyon	Paris										
Client_ID	Nom	Ville_Actuelle	Ville_Precedente																
101	Jean Dupont	Lyon	Paris																

Avantages et Inconvénients des 3 types de modélisation :

Type de modélisation	Avantages	Inconvénients
Etoile	- Nombre de jointures plus limitées donc gain de temps dans les recherches - Analyse plus simpliste et intuitive	- Redondance des données - Redondance qui mène à des coûts de calcul et de stockage élevé - Mise à jour des valeurs qui peut mener à des incohérences - Peu adapté si les dimensions/hierarchies sont plus complexes
Flocon	- Moins de redondance - MAJ des valeurs plus cohérente - Moins de stockage nécessaire - Meilleure organisation des hiérarchies (normalisation)	- Moins simplifié donc plus complexe à interpréter pour les utilisateurs - Requêtes plus lentes et plus coûteuse car plus de jointures (selon les requêtes) - Maintenance qui reste compliquée
Constellation	- Evite les doublons sur les tables de dimensions en les réutilisant pour plusieurs tables des faits - Permet de modéliser plusieurs domaines en un seul schéma - Analyses croisées entre plusieurs domaines plus cohérentes	- Plus complexe à comprendre - Requêtes lourdes qui prennent plus de temps - Difficulté de conception et risque d'erreur et d'incohérence entre les faits

On va se projeter sur des cas à **n dimensions**.

Pour chaque carré représenté pour un temps donné et un produit donné, l'ensemble des faits associés.



Cubes de données (faits + dimensions)

Soustraction de dimension : Passer d'un objet tri-dimensionnel à un objet bi-dimensionnel, mais risque de déformation (Ex : avec le planisphère en 3d qui est « déformé en 2d)

Projection stéréographique : Projection qui permet de faire un mobile dans un temps donné pour pouvoir changer le critère de déformation dans le temps. L'objectif c'est que l'élément déformé ne soit pas toujours le même.

Maintenant on peut faire des manipulations sur ces cubes : Sélection, Insertion, Projection...

- **Rotate** : Si on veut effectuer une manipulation en fonction de 2 critères, il va falloir **pivoter** le cube pour obtenir ces deux critères. On ne touche pas la structure mais on va juste bouger l'axe de projection.
- **Slicing** : Tranchage d'un cube afin d'obtenir des infos datées (on va slicer généralement en fonction du temps). On ne veut travailler que sur une seule dimension.
- **Dicing** : Faire un sous cube, extraire une partie du cube. Mais sur plusieurs dimensions.

◆ 1. Slicing (Découpage)

Mémoire pleine ⓘ

- **Définition** : Le *slicing* consiste à **fixer une dimension** du cube à une valeur particulière pour obtenir une sous-partie du cube.
- **Exemple** :

Si ton cube contient **Ventes** avec les dimensions *Temps, Produit, Région* :

- Cube complet → [Ventes par Produit, Région, Temps]
- **Slice** : fixer `Année = 2024` → tu obtiens un cube 2D (Produit × Région).

👉 C'est comme **prendre une tranche** du cube.

◆ 2. Dicing (Découpage en sous-cube)

- **Définition** : Le *dicing* consiste à **appliquer un filtre sur plusieurs dimensions** pour extraire un **sous-cube**.
- **Exemple** :

Toujours avec le cube [Ventes × Produit × Région × Temps] :

- **Dice** : sélectionner `Année = 2024`, `Produit ∈ {Pizza, Pasta}`, `Région = Europe`.
→ Résultat : un sous-cube restreint, mais qui peut rester multidimensionnel.

👉 C'est comme **découper un petit cube dans le grand cube**.

◆ 3. Rotation (ou Pivoting)

- **Définition** : Le *rotation* (ou *pivot*) consiste à **changer la perspective** du cube en réorganisant les dimensions (changer les axes).
- **Exemple** :

Si actuellement ton tableau croisé est :

- Lignes : *Produits*
- Colonnes : *Années*
- Mesure : *Ventes*
- Après rotation :
- Lignes : *Années*
- Colonnes : *Produits*

👉 C'est comme **tourner le cube** pour avoir une nouvelle vision des données.

Si on zoome sur un cube en particulier, on s'aperçoit qu'il est constitué de plusieurs cubes (agrégation de données).

Il existe plusieurs actions :

- **Drill-Down** : Approfondir le niveau de détails des données

- EX : Passer de

	2023	2024
Pomme	4	5
Poire	9	4

A ça :

	23/11	23/12	24/11	24/12
Pomme	2	2	2	3
Poire	5	1	4	3

- **Roll-up** : Globaliser nos données, les simplifier

- EX : Passer de :

	2023	2024
Pomme	4	5
Poire	9	4

A ça :

	2023	2024
Alimentaire	13	9

Ce niveau de détails est dépendant de la granularité du schéma.

Le drill-down peut se faire sur un schéma en étoile, mais il passera pas d'une table à l'autre mais d'un champ à l'autre.

On ne sera plus en SQL mais en MDX.

Dans le select de notre MDX, on va pouvoir dire 'On rows' ou 'On Columns ' afin de spécifier si on veut voir par ligne ou colonne.