

Fiche de Révision : Règles d'Association et Application avec RapidMiner

1.0 Introduction aux Concepts Clés des Règles d'Association

L'analyse par règles d'association est une technique fondamentale de la fouille de données (data mining), au même titre que la classification et le clustering. Son objectif est de découvrir des relations et des motifs cachés au sein de vastes ensembles de données, en particulier les données transactionnelles. Cette section pose les bases théoriques indispensables pour comprendre comment extraire ces relations significatives, en définissant les concepts de support et de confiance qui permettent de quantifier la pertinence d'une règle.

1.1 Contexte : Les Grandes Familles d'Analyse de Données

Pour mieux situer les règles d'association, il est utile de les comparer à deux autres grandes familles d'analyse de données :

- **Associations** : Cette approche vise à identifier des produits ou des événements qui apparaissent fréquemment ensemble. Par exemple, un hypermarché peut analyser les tickets de caisse pour découvrir que les clients qui achètent des cacahuètes ont une forte tendance à acheter également de la bière.
- **Classifications** : L'objectif est de construire un modèle prédictif à partir de données historiques pour attribuer une classe à de nouvelles observations. Une banque, par exemple, peut analyser l'historique de ses clients (profil, remboursements) pour créer un modèle capable de classer un nouveau demandeur de crédit comme étant un "bon" ou un "mauvais" payeur.
- **Clustering (Regroupement)** : Cette technique consiste à regrouper des données en sous-ensembles homogènes (clusters) sans connaissance préalable des groupes. Un distributeur peut utiliser les données des cartes de fidélité pour identifier des groupes de clients ayant des comportements d'achat similaires, afin de leur adresser des campagnes publicitaires ciblées et pertinentes.

1.2 Définition Fondamentale d'une Règle d'Association

Une règle d'association est un motif qui décrit une relation de type "si... alors..." entre des ensembles d'items.

1. **Structure** : Une règle se présente sous la forme Corps $\rightarrow$ Tête. Le "Corps" (ou prémisse) est l'ensemble d'items que l'on observe, et la "Tête" (ou conclusion) est l'ensemble d'items que l'on s'attend à trouver en conséquence.
2. **Exemple** : La règle achète(x, "cacahuètes") $\rightarrow$ achète(x, "bière") signifie que si un client x achète des cacahuètes, il est probable qu'il achète aussi de la bière.
3. **Objectif Principal** : À partir d'une base de transactions (par exemple, des tickets de caisse), l'objectif est de trouver toutes les règles qui expriment une corrélation statistiquement significative entre des ensembles d'items.

1.3 Les Mesures Indispensables : Support et Confiance

Pour évaluer si une règle est intéressante et non le fruit du hasard, deux mesures statistiques sont essentielles : le support et la confiance.

1. **Support** : Le support mesure la fréquence d'apparition d'un ensemble d'items dans la totalité des transactions. Il s'agit de la probabilité qu'une transaction prise au hasard contienne tous les items de l'ensemble (par exemple, {X, Y, Z}). En d'autres termes, le support est un simple indicateur de popularité : est-ce que cet ensemble d'articles apparaît souvent dans les paniers des clients ? Il est important de noter que le support d'une règle comme $X \& Y \Rightarrow Z$ est identique à celui de $X \& Z \Rightarrow Y$, car il concerne la fréquence de l'ensemble complet {X, Y, Z}.
2. **Confiance** : La confiance est une probabilité conditionnelle. Elle mesure la fiabilité de la règle. Pour une règle $X \& Y \rightarrow Z$, la confiance indique la probabilité qu'une transaction contenant déjà {X, Y} contienne également Z. La confiance, elle, mesure la fiabilité de l'inférence : si nous avons déjà le Corps de la règle dans notre panier,

quelle est la probabilité que nous y trouvions aussi la Tête ? Sa formule est : $\text{Confiance} = \frac{\text{Support}(\{X,Y,Z\})}{\text{Support}(\{X,Y\})}$

Exemple Détaillé

Considérons la base de transactions suivante avec un support minimum de 50% et une confiance minimum de 50%.

ID Transaction	Items
1000	A, C
2000	A, B, C
4000	A, D
5000	B, E, F

Sur 4 transactions au total :

- $\text{Support}(\{A\}) = 3/4 = 75\%$
- $\text{Support}(\{C\}) = 2/4 = 50\%$
- $\text{Support}(\{A, C\}) = 2/4 = 50\%$

Analysons deux règles possibles :

- **Règle A $\Rightarrow$ C**
 - **Support** : Le support de {A, C} est de **50%** (présent dans 2 transactions sur 4).
 - **Confiance** : Parmi les 3 transactions contenant A, 2 contiennent aussi C. La confiance est donc de $2/3$, soit **66.6%**.
- **Règle C $\Rightarrow$ A**
 - **Support** : Le support de {A, C} est également de **50%**.
 - **Confiance** : Parmi les 2 transactions contenant C, les 2 contiennent aussi A. La confiance est donc de $2/2$, soit **100%**.

Le calcul de ces mesures sur des millions de transactions nécessite des algorithmes efficaces, ce qui nous amène à la section suivante.

2.0 Algorithmes d'Extraction des Ensembles Fréquents

L'extraction des ensembles d'items fréquents (ceux dont le support dépasse un seuil défini) est l'étape la plus coûteuse en calcul dans le processus de découverte de règles. C'est un prérequis indispensable à la génération des règles elles-mêmes. L'efficacité de l'algorithme choisi est donc cruciale pour la faisabilité de l'analyse sur de grands volumes de données.

2.1 L'Approche Naïve et ses Limites

Comment trouver ces ensembles fréquents ? La première idée, la plus simple, serait de tout tester. Mais est-ce réalisable ?

1. **Fonctionnement** : L'algorithme parcourt la base de données pour chaque sous-ensemble d'items potentiel et compte ses occurrences pour vérifier s'il dépasse le seuil de support minimum.
2. **Coût et Limites** : Le principal inconvénient de cette méthode est son coût exorbitant. Si n est le nombre total d'items uniques, il existe 2^n sous-ensembles possibles. L'algorithme devrait donc parcourir la base de données 2^n fois, ce qui le rend totalement impraticable pour tout jeu de données de taille réaliste.

2.2 L'Algorithme Apriori : Une Approche Structurée

L'algorithme Apriori propose une solution beaucoup plus intelligente en utilisant une propriété fondamentale pour réduire l'espace de recherche.

2.2.1 Le Principe Fondamental

Le principe d'Apriori est le suivant : **Si un ensemble est non fréquent, alors tous ses sur-ensembles sont également non fréquents.**

Par exemple, si l'itemset {A} n'atteint pas le seuil de support minimum, il est inutile de calculer le support de {A, B}, car ce dernier ne pourra mathématiquement pas être fréquent. Cette propriété permet d'élaguer massivement l'arbre des combinaisons à tester.

2.2.2 Le Fonctionnement Itératif

L'algorithme procède de manière itérative, niveau par niveau :

1. **Génération par niveau** : Il commence par trouver les itemsets fréquents de taille 1 (L1). Ensuite, il utilise L1 pour générer les candidats de taille 2 (C2), puis teste leur support pour trouver L2, et ainsi de suite. Le processus s'arrête lorsqu'aucun nouvel itemset fréquent ne peut être trouvé.
2. **Étape de Jointure (self-join)** : Pour générer les candidats de taille k (Ck), l'algorithme joint les itemsets fréquents de taille k-1 (Lk-1) avec eux-mêmes.
3. **Étape d'Élagage (pruning)** : Avant de scanner la base de données, l'algorithme applique le principe fondamental : tout candidat de Ck dont un sous-ensemble de taille k-1 n'appartient pas à Lk-1 est immédiatement supprimé. Cette étape d'élagage est l'application directe du principe fondamental d'Apriori : en vérifiant que tous les sous-ensembles d'un candidat sont déjà connus comme fréquents, on élimine en amont des candidats qui sont mathématiquement garantis d'être non fréquents, évitant ainsi un scan inutile de la base de données.

2.2.3 Les Problématiques de l'Apriori

Bien que bien plus efficace que l'approche naïve, Apriori a ses propres limites :

- **Génération massive de candidats** : Même avec l'élagage, le nombre de candidats peut exploser. Par exemple, 10^4 itemsets fréquents de taille 1 peuvent potentiellement générer jusqu'à 10^7 candidats de taille 2, ce qui reste coûteux en mémoire et en temps de calcul.
- **Scans multiples de la base de données** : L'algorithme doit scanner l'intégralité de la base de données à chaque itération. Pour trouver les n-itemsets fréquents, il faut effectuer n+1 scans complets.

2.3 L'Algorithme FP-Growth : L'Alternative sans Génération de Candidats

L'algorithme FP-Growth (Frequent Pattern Growth) a été conçu pour surmonter les deux principaux problèmes d'Apriori.

2.3.1 Principe : Compression et Exploration

FP-Growth repose sur deux idées clés :

- **Compression des données** : Il évite les scans répétés en compressant la base de données transactionnelle dans une structure de données arborescente très compacte, le **FP-tree**. La construction de cet arbre ne nécessite que deux parcours de la base de données.
- **Pas de génération de candidats** : L'extraction des motifs fréquents se fait directement sur cette structure en mémoire via une approche "diviser-pour-régner", ce qui élimine complètement l'étape coûteuse de génération de candidats.

2.3.2 Les Grandes Étapes de FP-Growth

Le processus se déroule en deux temps :

1. **Construction du FP-tree** : Un premier parcours de la base de données sert à compter le support de chaque item et à créer une liste triée par ordre de fréquence décroissante. Un second parcours lit chaque transaction, la réorganise selon l'ordre de la liste, et l'insère dans le FP-tree. Les chemins dans l'arbre qui partagent des préfixes communs sont fusionnés pour maximiser la compression.
2. **Exploration (Mining)** : L'algorithme explore l'arbre de manière récursive. L'exploration se fait de manière astucieuse en partant des items les moins fréquents de la liste (en bas de l'arbre). Cette approche 'diviser-pour-régner' permet de traiter d'abord les cas les plus spécifiques et de reconstruire progressivement les motifs plus complexes, en travaillant sur des sous-arbres (FP-trees conditionnels) de plus en plus petits.

Bien que ces algorithmes soient puissants pour identifier des motifs récurrents, l'interprétation de ces derniers nécessite une analyse plus fine pour s'assurer qu'ils représentent une véritable relation et non une simple coïncidence.

3.0 Au-delà du Support et de la Confiance : La Notion de Corrélation

Le support et la confiance sont des indicateurs utiles, mais ils peuvent parfois être trompeurs et mener à des conclusions erronées. Mais que se passe-t-il si une règle a un bon support et une bonne confiance, mais ne nous apprend rien de nouveau ? C'est ici que ces mesures classiques montrent leurs limites. Cette section analyse ces écueils et introduit la notion de corrélation, une mesure plus robuste pour évaluer la pertinence réelle d'une règle.

3.1 Les Limites des Mesures Classiques

Considérons l'exemple suivant, portant sur un groupe de 5000 étudiants :

	Joue au basket	Ne joue pas au basket	Total
Prend des céréales	2000	1750	3750
Ne prend pas de céréales	1000	250	1250
Total	3000	2000	5000

Analysons la règle Jouer au basket -> prendre des céréales :

- **Support** : 2000 étudiants sur 5000 jouent au basket ET prennent des céréales, soit un support de **40%**.
- **Confiance** : Parmi les 3000 étudiants qui jouent au basket, 2000 prennent des céréales, soit une confiance de $2000/3000 = 66.7\%$.

Ces chiffres semblent élevés. Cependant, la probabilité de base qu'un étudiant (quel qu'il soit) prenne des céréales est de $3750/5000 = 75\%$. Le fait de savoir qu'un étudiant joue au basket *diminue* en réalité la probabilité qu'il prenne des céréales (de 75% à 66.7%). La règle est donc non seulement peu informative, mais trompeuse.

3.2 L'Importance de la Corrélation (Lift ou Intérêt)

Pour éviter ce genre de paradoxe, il est essentiel d'utiliser une mesure de corrélation, souvent appelée **Lift** ou **Intérêt**. Le Lift mesure à quel point la présence du corps de la règle augmente (ou diminue) la probabilité de la présence de la tête.

La formule du Lift pour une règle $A \rightarrow B$ est : $\text{corr}(A,B) = P(A \wedge B) / (P(A) * P(B))$

L'interprétation de la valeur du Lift est directe :

- **Lift = 1** : A et B sont statistiquement indépendants. La règle n'apporte aucune information.
- **Lift > 1** : A et B sont positivement corrélés. La présence de A augmente la probabilité de la présence de B. La règle est potentiellement intéressante.
- **Lift < 1** : A et B sont négativement corrélés. La présence de A diminue la probabilité de la présence de B.

Considérons un exemple où la règle $X \rightarrow Z$ a une confiance de 75%, tandis que la règle $X \rightarrow Y$ n'a qu'une confiance de 50%. Intuitivement, la première règle semble plus forte. Cependant, l'analyse de la corrélation (Lift) révèle une réalité différente :

Itemset	Support	Intérêt (Lift)
(X, Y)	25%	2.0
(X, Z)	37,5%	0.9
(Y, Z)	12,5%	0.57

Ici, le Lift de 2.0 pour (X, Y) indique une forte corrélation positive, rendant cette association très pertinente. À l'inverse, le Lift de 0.9 pour (X, Z) montre une légère corrélation négative, suggérant que la règle n'est pas intéressante malgré sa confiance élevée.

La compréhension de ces concepts théoriques est la clé pour appliquer et interpréter correctement les résultats fournis par un outil pratique comme RapidMiner.

4.0 Mise en Pratique avec RapidMiner

Cette section fait le pont entre la théorie et la pratique en décrivant les étapes concrètes pour implémenter un processus d'extraction de règles d'association dans l'outil RapidMiner. Ce workflow s'appuie directement sur les concepts de support, de confiance et sur l'efficacité de l'algorithme FP-Growth.

4.1 Étape 1 : Préparation des Données Transactionnelles

Les algorithmes comme FP-Growth fonctionnent en analysant les "paniers" ou "transactions" complets. Ils ont besoin de voir tous les articles achetés ensemble sur une seule ligne pour pouvoir identifier les co-occurrences. Le format initial, avec un produit par ligne, rend cette analyse impossible, d'où la nécessité de reconstruire ces paniers.

1. Utilisez l'opérateur **Aggregate**. Cet outil est crucial pour regrouper les données par numéro de facture (Invoice ou N°Ticket) et concaténer tous les produits associés à cette facture sur une seule ligne.
2. Appliquez les opérateurs de nettoyage **Select Attributes** pour ne conserver que la nouvelle colonne contenant les produits concaténés, et **Rename** pour lui donner un nom explicite (par exemple, "Produits").

4.2 Étape 2 : Extraction des Motifs Fréquents avec FP-Growth

Une fois les données au bon format, l'étape suivante consiste à identifier les ensembles d'items qui apparaissent fréquemment.

1. Insérez l'opérateur **FP-Growth**. Cet opérateur implémente l'algorithme du même nom pour trouver les itemsets fréquents de manière efficace.
2. Paramétrez le seuil de support (min support). Le choix de ce seuil est critique. Un seuil trop élevé (ex: 0.95) peut ne retourner aucun résultat, tandis qu'un seuil trop bas peut générer un nombre écrasant de motifs. Il est souvent nécessaire de l'ajuster de manière itérative (par exemple, en le baissant à 0.01 pour commencer à obtenir des résultats).
3. Il est conseillé de décocher l'option "find min number of itemsets" pour garder un contrôle précis sur le processus basé uniquement sur le seuil de support.

4.3 Étape 3 : Génération des Règles d'Association

À partir des itemsets fréquents extraits à l'étape précédente, nous pouvons maintenant générer les règles d'association.

1. Ajoutez l'opérateur **Create Association Rules** à la suite de l'opérateur FP-Growth.

2. Définissez le seuil de confiance minimal (min confidence). Ce paramètre filtrera les règles pour ne conserver que celles qui sont jugées suffisamment fiables. Une valeur commune pour commencer est 0.5 (soit 50%).

4.4 Étape 4 : Analyse et Interprétation des Résultats

Les résultats sont généralement présentés dans un tableau contenant les règles et leurs mesures associées. L'interprétation se concentre sur les colonnes suivantes :

- **Premises** : Le corps de la règle (le "si...").
- **Conclusion** : La tête de la règle (le "...alors").
- **Confiance** : La confiance de la règle.
- **Lift** : La corrélation, indicateur clé de la pertinence.

Voici comment interpréter les valeurs clés :

- **Lift supérieur à 1** : L'association est positivement corrélée. Cela signifie que la présence du produit dans les prémisses favorise la présence du produit dans la conclusion. C'est une règle potentiellement intéressante.
- **Confiance de 1 (100%)** : Cette valeur indique une certitude. Dans 100% des cas où les produits des prémisses sont présents dans une transaction, le produit de la conclusion l'est aussi.

Il est possible de sauvegarder le processus RapidMiner ainsi créé pour le réutiliser. Cependant, il faut garder à l'esprit qu'un tel processus est souvent spécifique au jeu de données pour lequel il a été conçu.

5.0 Synthèse pour la Révision

Cette fiche a démontré que la maîtrise des règles d'association est un processus en trois volets : la compréhension de la **théorie** (Support, Confiance et les limites qui mènent au Lift), la connaissance des **algorithmes** (le passage de l'approche coûteuse d'Apriori à l'efficacité de FP-Growth), et la maîtrise de la **pratique** (l'implémentation d'un workflow logique dans un outil comme RapidMiner).

5.1 Comparatif des Algorithmes

Critère	Apriori	FP-Growth
Principe de base	Approche itérative (par niveau) basée sur l'élagage des sur-ensembles non fréquents.	Compression de la base de données dans une structure arborescente (FP-tree).
Génération de candidats	Oui, génère un grand nombre de candidats à chaque niveau.	Non, aucune génération de candidats n'est nécessaire.
Nombre de scans de la base	Multiple (k+1 scans pour trouver les k-itemsets).	Deux scans seulement, quel que soit le nombre de motifs.
Principal avantage	Simplicité conceptuelle et principe facile à comprendre.	Très efficace en mémoire et en temps de calcul, surtout sur des données denses.

5.2 Points Clés à Retenir

- **Règle d'Association** : Une relation de la forme Corps -> Tête qui exprime une co-occurrence probable entre des ensembles d'items.
- **Support** : Mesure la fréquence d'un ensemble d'items dans la totalité des transactions. C'est un indicateur de popularité.
- **Confiance** : Mesure la probabilité conditionnelle que la Tête apparaisse si le Corps est déjà présent. C'est un indicateur de fiabilité.

- **Limites** : Le support et la confiance seuls peuvent être trompeurs, car ils n'évaluent pas la dépendance réelle entre les items.
- **Lift (Corrélation)** : Mesure essentielle qui compare la probabilité d'observer la Tête avec et sans la présence du Corps. Un **Lift** > 1 indique une corrélation positive et donc une règle potentiellement pertinente.
- **Processus en 2 étapes** : L'extraction se fait toujours en deux temps : 1. Trouver les ensembles d'items fréquents. 2. Générer des règles à partir de ces ensembles.
- **RapidMiner** : Le workflow pratique typique pour cette tâche utilise une séquence d'opérateurs : **Aggregate** (préparation), **FP-Growth** (extraction des motifs), et **Create Association Rules** (génération des règles).