

Fiche de Révisions : Le Clustering et son Application Pratique

1. Introduction aux Principes Fondamentaux du Clustering

Le clustering, ou regroupement, est une technique d'analyse de données non supervisée. Son objectif stratégique est de découvrir des structures et des groupes naturels (appelés *clusters*) au sein d'un jeu de données sans aucune connaissance préalable des catégories existantes. Contrairement à la classification, où les étiquettes sont connues à l'avance, le clustering explore les données pour y déceler des affinités intrinsèques. Le succès de cette démarche repose entièrement sur la notion de **similarité** : les objets sont regroupés en fonction de leur ressemblance.

1.1. Définition d'un Regroupement de Qualité

Un algorithme de clustering performant vise à créer des groupes qui respectent deux critères fondamentaux :

- **Grande similarité intra-groupe** : Les objets appartenant à un même groupe doivent être aussi semblables que possible les uns par rapport aux autres.
- **Faible similarité inter-groupe** : Les objets appartenant à des groupes différents doivent être aussi dissemblables que possible.

En définitive, la qualité d'un regroupement dépend de manière critique de la pertinence de la mesure de similarité choisie et de la manière dont elle est implémentée par l'algorithme.

1.2. Structures de Données Essentielles

Pour réaliser un clustering, les données sont généralement organisées selon deux structures principales :

- **Matrice de données** : Un tableau standard où les lignes représentent les objets (par exemple, des clients) et les colonnes représentent leurs attributs ou variables (âge, salaire, etc.).
- **Matrice de distance** : Un tableau carré qui stocke la dissimilarité calculée entre chaque paire d'objets du jeu de données.

Pour pouvoir construire et exploiter ces matrices, il est impératif de savoir comment quantifier objectivement la similarité entre les objets.

2. La Mesure de la Similarité : Préparation et Calcul

La quantification de la similarité, généralement effectuée via une mesure de distance, constitue l'étape la plus cruciale du processus de clustering. Un choix inapproprié peut mener à des regroupements dénués de sens. Le traitement des données et le choix de la métrique de distance doivent donc être scrupuleusement adaptés au type de variables présentes (numériques, binaires, etc.) pour garantir la pertinence des résultats.

2.1. Traitement des Variables d'Intervalle (Numériques)

Lorsque les variables sont numériques, comme un âge et un salaire, leurs échelles de valeurs peuvent être très différentes. Sans traitement préalable, la variable avec l'échelle la plus grande (le salaire, variant sur des milliers d'unités) dominera complètement le calcul de distance, rendant la contribution de la variable à plus faible échelle (l'âge) quasi insignifiante.

La **standardisation des données** est donc une étape indispensable. La méthode du **Z-score** permet de transformer toutes les valeurs pour qu'elles soient exprimées dans la même unité statistique, centrées autour de 0.

Le calcul du Z-score s'effectue en trois étapes :

1. **Calculer la moyenne** (mf) pour l'ensemble des valeurs de la variable.
2. **Calculer l'écart absolu moyen** (sf), qui mesure à quel point chaque valeur s'éloigne en moyenne de mf .
3. **Calculer le Z-score** pour chaque valeur xif en appliquant la formule : $z = (xif - mf) / sf$.

Notez que cette version du Z-score utilise l'écart absolu moyen (sf), et non l'écart-type plus commun. Le score z représente donc de combien de fois l'écart absolu moyen une valeur s'écarte de la moyenne de sa variable.

Données Brutes	Âge	Salaire
Personne 1	50	11000
Personne 2	70	11100
Personne 3	60	11122
Données Standardisées	Z-score Âge	Z-score Salaire
Personne 1	-2.0	-2.0
Personne 2	2.0	0.70
Personne 3	0.0	1.30

2.2. Le Calcul de la Distance : Métriques Courantes

La **distance de Minkowski** est une formule généralisée qui sert de base à plusieurs métriques de distance courantes entre deux objets i et j .

$$d(i,j) = (|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \dots + |x_{ip} - x_{jp}|^q)^{1/q}$$

où $i = (x_{i1}, \dots, x_{ip})$ et $j = (x_{j1}, \dots, x_{jp})$ sont deux objets décrits par p variables. Le terme $|x_{if} - x_{jf}|$ représente la différence entre les valeurs de ces deux objets pour la f -ième variable.

Les deux cas d'utilisation les plus fréquents sont :

- **Distance de Manhattan ($q=1$)** : Elle additionne les écarts absolus entre les coordonnées des objets. $d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ip} - x_{jp}|$
- **Distance Euclidienne ($q=2$)** : Elle correspond à la distance "à vol d'oiseau" entre deux points dans un espace. $d(i,j) = \sqrt{|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \dots + |x_{ip} - x_{jp}|^2}$

L'exemple suivant, basé sur la distance de Manhattan, illustre l'impact critique de la standardisation :

Avant standardisation :

- $d(p1, p2) = |50-70| + |11000-11100| = 20 + 100 = 120$
- $d(p1, p3) = |50-60| + |11000-11122| = 10 + 122 = 132$
- Conclusion: $p1$ ressemble plus à $p2$ qu'à $p3$ $\wedge$

Après standardisation (Z-score) :

- $d(p1, p2) = |-2 - 2| + |-2 - 0.7| = 4 + 2.7 = 6.7$
- $d(p1, p3) = |-2 - 0| + |-2 - 1.3| = 2 + 3.3 = 5.3$
- Conclusion: $p1$ ressemble plus à $p3$ qu'à $p2$ $\wp$

La standardisation a inversé la conclusion, produisant un résultat statistiquement plus fiable.

2.3. Traitement des Autres Types de Variables

Le traitement des données non numériques requiert des approches spécifiques.

Type de Variable	Méthodes et Métriques
Binaires	On distingue les variables symétriques (ex: Sexe), où 0 et 1 ont le même poids, des variables asymétriques (ex: test HIV positif), où l'une des valeurs (souvent la plus rare,

	codée 1) est plus significative. Pour calculer la distance, on utilise une table de contingence qui compte les correspondances entre deux objets i et j :
:---	:---
Objet i	1
	0
 • Coefficient d'appariement simple : $d(i,j) = (b+c)/(a+b+c+d)$. Tient compte de tous les cas (y compris d, les correspondances 0-0). Adapté aux variables symétriques. • Coefficient de Jaccard : $d(i,j) = (b+c)/(a+b+c)$. Ignore les cas où les deux objets ont la valeur 0 (appariements 0-0). Adapté aux variables asymétriques.	
Nominales	Variables catégorielles sans ordre (ex: couleur). • Matching simple : $d(i,j) = (p-m)/p$, où p est le nombre total de variables et m le nombre de correspondances. • Transformation en variables binaires : Créer une nouvelle variable binaire pour chaque modalité possible (ex: une variable "Rouge", une "Bleu", etc.).
Ordinales	Variables avec un ordre logique mais sans distance précise entre les valeurs (ex: S, M, L). 1. Remplacer la valeur par son rang (ex: S=1, M=2, L=3). 2. Normaliser ce rang entre [0, 1] avec la formule $zif = (rif - 1) / (Mf - 1)$, où rif est le rang et Mf le nombre total de rangs possibles.

Une fois que la méthode de calcul de distance entre les objets est clairement définie, différents algorithmes peuvent être appliqués pour former les groupes.

3. Panorama des Algorithmes de Clustering

Il existe de nombreuses approches pour effectuer un clustering. Elles peuvent être classées en trois grandes familles, chacune possédant une logique, des forces et des faiblesses qui la rendent plus ou moins adaptée à certains types de données et d'objectifs. Les principales familles sont les algorithmes de partitionnement, les algorithmes hiérarchiques et ceux basés sur la densité.

3.1. Algorithmes de Partitionnement : K-Means

L'algorithme K-Means (ou K-Moyennes) est l'une des méthodes de partitionnement les plus connues. Son principe est de représenter chaque cluster par un point central appelé **barycentre** (ou moyenne des points du cluster).

L'objectif est d'affecter chaque objet de données au cluster dont le centre est le plus proche, de manière à minimiser la somme des distances intra-cluster.

L'algorithme se déroule comme suit :

1. Choisir aléatoirement k objets dans les données pour servir de centres initiaux aux k clusters.
2. **Répéter jusqu'à stabilisation** (c'est-à-dire jusqu'à ce que les objets ne changent plus de cluster) :
 - **Affectation** : Affecter chaque objet au cluster dont le centre est le plus proche.
 - **Mise à jour** : Recalculer le centre (la moyenne) de chaque cluster en se basant sur les objets qui lui sont désormais affectés.

Par exemple, pour un ensemble $A=\{1,2,3,6,7,8,13,15,17\}$ et $k=3$, le processus se déroule itérativement. Initialement, avec des centres à 1, 2, et 3, le point 6 est affecté au cluster C3. Après la mise à jour des centres, les points sont réévalués : 3, initialement dans C3, se déplace vers C2 car il est plus proche du nouveau centre $M2=2.5$. Ce processus itératif se poursuit jusqu'à ce qu'aucun point ne change de cluster, menant à la configuration finale stable : $C1=\{1,2,3\}$, $C2=\{6,7,8\}$, et $C3=\{13,15,17\}$.

- **Forces :**
 - Relativement simple et efficace en termes de temps de calcul, même sur de grands jeux de données.
 - Tendance à créer des clusters compacts et de taille similaire.
- **Faiblesses :**
 - Le nombre de clusters k doit être spécifié à l'avance.
 - Très sensible au choix des centres initiaux et aux données aberrantes (*outliers*).
 - Incapable de découvrir des groupes de formes non-convexes (non sphériques).
 - Ne fonctionne qu'avec des données numériques, car son mécanisme central de mise à jour repose sur le calcul de la moyenne (le barycentre), une opération qui n'est pas définie pour les variables catégorielles.

3.2. Algorithmes Hiérarchiques

Le clustering hiérarchique crée une **décomposition hiérarchique** des objets, souvent visualisée sous la forme d'un arbre appelé **dendrogramme**. Contrairement à K-Means, il n'est pas nécessaire de spécifier le nombre de clusters k à l'avance ; on définit plutôt une condition d'arrêt (par exemple, un seuil de distance).

Il existe deux approches principales :

- **Agglomérative (AGNES) :** Approche ascendante (*bottom-up*). Au départ, chaque objet forme son propre cluster. Ensuite, les clusters les plus proches sont progressivement fusionnés jusqu'à ce qu'il ne reste plus qu'un seul grand cluster contenant tous les objets.
- **Divisive (DIANA) :** Approche descendante (*top-down*). Au départ, tous les objets sont dans un seul et même cluster. Celui-ci est ensuite progressivement divisé en sous-clusters plus petits.

3.3. Algorithmes Basés sur la Densité : DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) aborde le problème différemment. Il définit les clusters comme des **régions denses** de l'espace, séparées par des régions de faible densité. Les points qui n'appartiennent à aucune région dense sont considérés comme du bruit.

L'algorithme repose sur deux paramètres clés :

- **Eps :** Le rayon du voisinage autour d'un point.
- **MinPts :** Le nombre minimum de points devant se trouver dans le voisinage d'un point (défini par Eps) pour que ce dernier soit considéré comme un point central ("attractif").

Son principe est de construire un graphe où deux points p et q sont reliés s'ils sont voisins ($\text{dist}(p,q) \leq \text{Eps}$) et si au moins l'un des deux est "attractif". Les clusters correspondent alors aux ensembles de points connectés dans ce graphe.

Cette approche confère à DBSCAN deux avantages majeurs par rapport à K-Means : sa capacité à trouver des **groupes de formes arbitraires (non-convexes)** et sa **robustesse face au bruit**, qu'il peut identifier et isoler.

Maintenant que nous avons exploré la logique de ces algorithmes, la section suivante démontrera de manière concrète comment ces différences théoriques se traduisent par des résultats radicalement différents face à des défis pratiques comme le bruit et l'échelle des données.

4. Application Pratique et Comparaison (Inspiré de RapidMiner)

Cette section se concentre sur les implications pratiques des choix théoriques présentés précédemment, en s'appuyant sur les résultats observés lors de travaux dirigés. Il est crucial de comprendre comment les algorithmes se comportent face à des défis courants comme la nécessité de normaliser les données ou la présence de valeurs aberrantes.

4.1. Impact de la Normalisation sur K-Means

Lors d'une application de K-Means (TD4), il a été observé que l'algorithme appliqué sur des données brutes (non normalisées) pouvait donner des résultats semblant corrects à première vue.

Cependant, la conclusion tirée après avoir normalisé les données est sans appel : bien que les résultats puissent paraître "empirés" en surface, la normalisation est une étape **nécessaire** qui rend les résultats **plus fiables** d'un point de vue statistique. Ignorer cette étape revient à laisser les variables à grande échelle dicter l'ensemble du processus de regroupement.

4.2. Gestion du Bruit : K-Means vs. DBSCAN

Dans un autre scénario (TD5), un point manifestement aberrant (10,5) a été ajouté à un jeu de données où les points étaient concentrés dans une zone plus restreinte. La réaction des deux algorithmes a été radicalement différente.

- **Comportement de K-Means** : L'algorithme s'est montré **très sensible au "bruit"**. Pour intégrer ce point aberrant, il a fortement déformé l'un des clusters existants en déplaçant son centre, compromettant ainsi la pertinence du regroupement global.
- **Comportement de DBSCAN** : DBSCAN a correctement identifié que ce point était isolé et ne correspondait à aucune région dense. Il l'a donc classé comme du **bruit ("Noise")**, préservant ainsi l'intégrité et la forme des clusters denses existants.

Cette expérience démontre la robustesse supérieure de DBSCAN dans les jeux de données réels, qui contiennent souvent des outliers ou du bruit.

4.3. Tableau de Synthèse Comparatif

Critère	K-Means	DBSCAN
Forme des clusters	Découvre uniquement des groupes convexes (sphériques).	Peut découvrir des groupes de formes arbitraires (non-convexes) .
Paramètres requis	Le nombre de clusters k doit être spécifié à l'avance.	Nécessite de spécifier Eps (rayon) et MinPts (densité).
Gestion des outliers (bruit)	Très sensible ; les outliers peuvent fortement influencer la position des centres.	Robuste ; identifie et isole les outliers comme du "bruit".
Type de données	Applicable principalement aux données numériques (à cause du calcul de la moyenne).	Applicable tant qu'une mesure de distance peut être définie.